Математическая статистика
Домашнее задание 1

Никита Загайнов

March 18, 2025

1. Эффективная оценка - это оценка, дисперсия которой достигает границы Крамера-Рао:

$$\mathsf{D}(\widehat{\theta}) = \frac{1}{ni(\theta)}$$

Она достигается в случае, если оценка является несмещённой, её функция плотности дифференцируема по оцениваемому параметру, её область определения не зависит от оцениваемого параметра, для любого θ существует информация Фишера, и распредение принадлежит экспоненциальному семейству. Функцию плотности из экспоненциального семейства можно записать следующим образом:

$$f(x,\theta) = h(x)\exp\left(\sum_{i=1}^{k} a_i(\theta)f_i(x) + b_i(\theta)\right)$$

Докажем, что нормальное распределение принадлежит экспоненциальному семейству. Функция плотности нормального распределения:

$$\begin{aligned} f(x,\alpha,\sigma^2) &= \frac{1}{\sqrt{2\pi\sigma^2}}\exp\left(-\frac{(x-\alpha)^2}{2\sigma^2}\right) \\ &= \frac{\exp\left(-\frac{1}{2\sigma^2}\right)}{\sqrt{2\pi\sigma^2}}\exp\left(x^2+2\alpha x+\alpha^2\right) \end{aligned}$$

Подставив

$$\begin{aligned} h(x) &= \frac{\exp\left(-\frac{1}{2\sigma^2}\right)}{\sqrt{2\pi\sigma^2}} \\ f_1(x) &= x^2 & a_1(\alpha) &= 1 \\ f_2(x) &= x & a_2(\alpha) &= 2\alpha \\ b_1(\alpha) &= \alpha^2 & b_2(\alpha) &= 0 \end{aligned}$$

Получим, что нормальное распределение принадлежит экспоненциальному семейству.

Проверим выполнение условий регулярности:

(a) Среднее по выборке - несмещённая оценка для α

(b) Функция плотности дифференцируема по α:

$$\frac{\partial}{\partial\alpha}f(x,\alpha,\sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}}\frac{x-\alpha}{\sigma^2}\exp\left(-\frac{(x-\alpha)^2}{2\sigma^2}\right)$$

(c) Область определения: $x \in (-\infty,\infty)$

(d) Информация Фишера существует:

$$i(\alpha) = -\mathbb{E}\left(\frac{\partial^2}{\partial\alpha^2}\ln f(x,\alpha,\sigma^2)\right) = \frac{1}{\sigma^2}$$

Тогда среднее по выборке является эффективной оценкой для α.

2. Оценка

$$\widehat{\sigma}^2 = \frac{1}{n}\sum_i^n$$

является несмещённой оценкой для σ^2:

$$\mathbb{E}(\widehat{\sigma}^2) = \mathbb{E}\left(\frac{1}{n}\sum_i^n X_i^2\right) = \frac{1}{n}\sum_i^n \mathbb{E}(X_i^2) = \frac{1}{n}\sum_i^n \sigma^2 = \sigma^2$$

Подставив в функцию плотности нормального распределения

$$h(x) = \frac{\exp\left(-\frac{x^2}{2}\right)}{\sqrt{2\pi}}$$

$$f_1(x) = 1 \qquad a_1(\sigma^2) = \frac{1}{\sigma^2} \quad b_1(\sigma^2) = \ln\frac{1}{\sigma}$$

Получим, что это распределение принадлежит экспоненциальному семейству. Проверим условия регулярности:

(a) Оценка несмещённая

(b) Функция плотности дифференцируема по σ^2:

$$\frac{\partial}{\partial(\sigma^2)} f(x,\sigma^2) = -\frac{1}{2\sqrt{2\pi}\sigma^3}\exp\left(-\frac{x^2}{2\sigma^2}\right) + \frac{x^2}{2\sqrt{2\pi}\sigma^5}\exp\left(-\frac{x^2}{2\sigma^2}\right)$$

(c) Область определения: $x \in (-\infty, \infty)$

(d) Информация Фишера существует:

$$i(\sigma^2) = -\mathbb{E}\left(\frac{\partial^2}{\partial(\sigma^2)^2}\ln f(x,\sigma^2)\right) = \frac{1}{2\sigma^4}$$

Тогда оценка является эффективной.

3. Применим теорему Леманна-Шеффе. Функция плотности для выборки:

$$p(X,0,\theta) = \prod_{i=1}^n \frac{1}{\theta} I(X_i \in [0,\theta]) = \frac{1}{\theta^n} I(X_{(n)} \le \theta)$$

Где $X_{(n)} = \max(X)$. Выберем статистику $T(X) = X_{(n)}$, тогда плотность принимает вид $p(X,\theta) = \frac{1}{\theta^n} I(T(X) \le \theta)$, что значит, что $T(X)$ является достаточной статистикой. Эта статистика также является полной. Для доказательства найдём функцию плотности для $T(X)$:

$$\begin{aligned}
P(T \le x) &= P(X_{(n)} \le x) = P(\max(X) \le x) = \\
&= \prod_{i=1}^n P(X_i \le x) = F(x)^n = \left(\frac{x}{\theta}\right)^n \\
p(x,n,\theta) &= \frac{d}{dx}P(T \le x) = \frac{n}{\theta^n}x^{n-1}
\end{aligned}$$

Проверим, что статистика $T(X)$ является полной:

$$\begin{aligned}
\mathbb{E}g(T) &= \int_0^\theta g(x)\frac{n}{\theta^n}x^{n-1}dx \\
&= \frac{n}{\theta^n}\int_0^\theta g(x)x^{n-1}dx = 0, \forall\theta \Longrightarrow \\
G &= \int_0^\theta g(x)x^{n-1}dx = 0, \forall\theta \iff \\
\frac{d}{d\theta}G &= g(x)x^{n-1} = 0, \forall\theta \iff \\
g(T) &= 0, \forall\theta
\end{aligned}$$

Тогда мы можем применить теорему Леманна-Шеффе, чтобы получить оптимальную оценку. Для этого приравняем математическое ожидание функции от статистики к θ:

$$\begin{aligned}
&\mathbb{E}g(T) = \theta \iff \\
&\int_0^\theta g(x)\frac{n}{\theta^n}x^{n-1}dx = \theta \iff \\
&\int_0^\theta g(x)x^{n-1}dx = \frac{\theta^{n+1}}{n} \iff \\
&g(x) = \frac{n+1}{n}x
\end{aligned}$$

Тогда оптимальной оценкой для θ является

$$\widehat{\theta} = \frac{n+1}{n}X_{(n)}$$

4. (a) Метод моментов для распределения $U(a,b)$:

$$\begin{aligned}
f_1(a,b) &= \frac{1}{n}\sum_{i=1}^n X_i \\
f_2(a,b) &= \frac{1}{n}\sum_{i=1}^n X_i^2
\end{aligned}$$

Для равномерного распределения известны среднее и дисперсия:

$$E(X) = \frac{a+b}{2}, \quad \mathsf{D}(X) = \frac{(b-a)^2}{12}$$

Подставим их в метод:

$$\begin{aligned}
\frac{a+b}{2} &= \frac{1}{n}\sum_{i=1}^n X_i \\
\frac{(b-a)^2}{12} &= \frac{1}{n}\sum_{i=1}^n X_i^2 - \frac{(a+b)^2}{4}
\end{aligned}$$

Откуда выражаем:

$$\begin{aligned}
a &= \frac{1}{n}\sum_{i=1}^n X_i - \sqrt{3}\sqrt{\frac{1}{n}\sum_{i=1}^n X_i^2 - \left(\frac{1}{n}\sum_{i=1}^n X_i\right)^2} \\
b &= \frac{1}{n}\sum_{i=1}^n X_i + \sqrt{3}\sqrt{\frac{1}{n}\sum_{i=1}^n X_i^2 - \left(\frac{1}{n}\sum_{i=1}^n X_i\right)^2}
\end{aligned}$$

(b) Следующий код был использован для тестирования метода:

```python
from typing import Tuple
import numpy as np
from matplotlib import pyplot as plt


def get_estimates(data: np.ndarray) -> Tuple[np.ndarray, np.ndarray]:
    first_moment = np.mean(data, axis=1)
    second_moment = np.mean(data * data, axis=1)
```

```python

    subtrahend = np.sqrt(3) * np.sqrt(second_moment - first_moment *
        first_moment)
    a = first_moment - subtrahend
    b = first_moment + subtrahend
    return a, b


def main():
    ns = np.logspace(1, 5, 10, dtype=int)
    trials = 1000

    a_true = -np.exp(2)
    b_true = np.pi * 2.5

    plt.figure(figsize=(10, 6))

    errors_a = []
    errors_b = []
    for n in ns:
        samples = np.random.uniform(a_true, b_true, (trials, n))
        a_est, b_est = get_estimates(samples)
        errors_a.append(np.mean((a_est - a_true) ** 2))
        errors_b.append(np.mean((b_est - b_true) ** 2))

    plt.plot(ns, errors_a, "o-", label="Error of a")
    plt.plot(ns, errors_b, "o-", label="Error of b")
    plt.xlabel("n")
    plt.ylabel("MSE")
    plt.legend()
    plt.grid()
    plt.yscale("log")
    plt.xscale("log")

    plt.savefig("task4.png")


if __name__ == "__main__":
    main()
```

На выходе получен график 1.

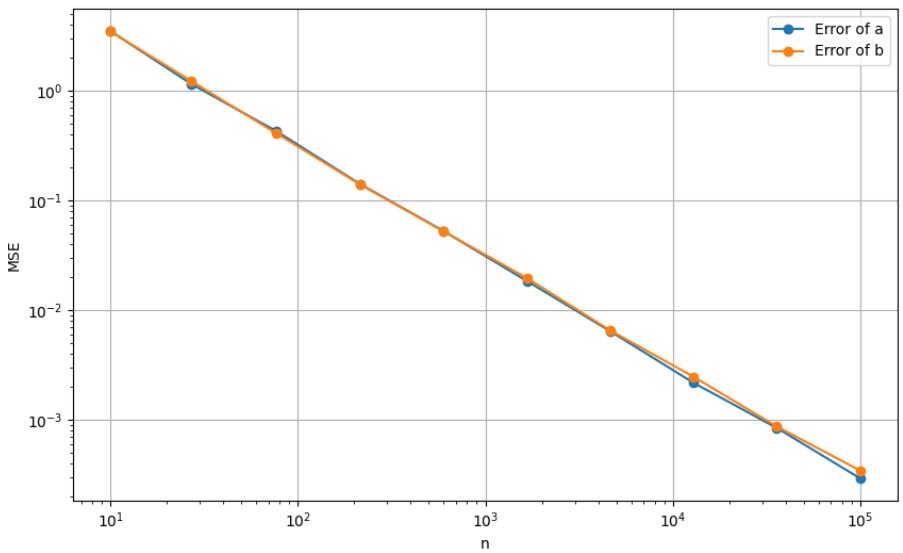

Figure 1: Зависимость среднеквадратичной ошибки от размера выборки

5. Запишем функцию правдоподобия для данного распределения на выборке $X_1, \ldots, X_n$:

$$p(X, \alpha) = \prod_{i=1}^{n} \alpha \exp(\alpha(X_i - \beta))$$

Прологарифмируем её:

$$\ln p(X, \alpha) = n \ln \alpha - n\beta + \alpha \sum_{i=1}^{n} (X_i)$$

Приравняем градиент к нулю:

$$\frac{\partial}{\partial \alpha} \ln p(X, \alpha) = 0$$
$$\frac{n}{\alpha} - n\beta + \sum_{i=1}^{n} X_i = 0$$
$$\alpha = \frac{n}{n\beta + \sum_{i=1}^{n} X_i}$$

Тогда состоятельной оценкой для α является

$$\widehat{\alpha} = \frac{n}{n\beta + \sum_{i=1}^{n} X_i}$$

6. Запишем функцию правдоподобия:

$$p(X, \theta) = \prod_{i=1}^{n} \frac{1}{5} I(X_i \in [\theta, \theta + 5])$$

Прологарифмируем её:

$$\ln p(X, \theta) = n \ln \frac{1}{5} + \sum_{i=1}^{n} I(X_i \in [\theta, \theta + 5])$$

Получившаяся функция недиффиренцируема, так что метод неприменим сам по себе. Но эту функцию можно максимизировать неградиентным методом: Возьмём $\theta = X_{(1)}$, тогда каждый элемент суммы будет равен 1, так как такая оценка гарантированно даст, что все элементы входят в интервал $[\theta, \theta + 5]$

Тогда состоятельной оценкой для θ является

$$\widehat{\theta} = X_{(1)}$$